UNIVERSIDAD POLITÉCNICA DE ATLAUTLA

ACTIVIDAD INTEGRADORA 3.1
TIPOS DE APRENDIZAJE AUTOMÁTICO

ALUMNA: DENISE ESTRADA FRANCO

MATRICULA: 24305019

GRUPO: 171

ASIGNATURA: FUNDAMENTOS DE INTELIGENCIA ARTIFICAL

DOCENTE: GARCÍA LARA JAVIER

FECHA DE ENTREGA: 06 noviembre 2026

1.1 Investigación conceptual

1.1.1 Concepto de aprendizaje automático

¿Qué es el aprendizaje automático?

Es la forma en que una computadora aprende a partir de ejemplos. En lugar de que una persona escriba todas las reglas, se le muestran muchos datos y el programa encuentra por sí mismo los patrones que los relacionan; después usa esos patrones para predecir o decidir en casos que nunca vio. Entre más y mejores datos recibe, mejor suele desempeñarse.

Mitchell (1997) plantea que un programa aprende cuando su desempeño en una tarea T, medido con una métrica P, mejora conforme gana experiencia E. En un filtro de spam: T es clasificar correos, E son los correos ya marcados por los usuarios y P es el porcentaje de aciertos.

IBM (s.f) lo describe como el campo donde los algoritmos identifican patrones en los datos para predecir valores: con datos suficientes, el sistema establece la relación entre las variables de entrada y el valor a predecir, y así estima valores nuevos a partir de otras entradas

¿Qué diferencia existe entre programación tradicional y aprendizaje automático?

Qué recibe y qué produce: En la programación tradicional una persona escribe las reglas y el programa, con los datos, produce respuestas. En el aprendizaje automático se entregan datos junto con sus respuestas conocidas (ejemplos) y el sistema produce las reglas, en forma de un modelo entrenado.

Cómo cambia su comportamiento: En la tradicional alguien tiene que modificar el código; en el aprendizaje automático basta con reentrenar el modelo con datos nuevos

Cuando conviene cada una: La programación tradicional sirve cuando las reglas son claras y estables (calcular un impuesto); el aprendizaje automático, cuando las reglas son difíciles de escribir o cambian (detectar spam, reconocer imágenes)

Riesgo principal: En la tradicional, reglas incompletas o desactualizadas; en el aprendizaje automático, datos sesgados, escasos o de mala calidad

¿Qué es un dataset, una etiqueta, una feature y una función pérdida?

Ejemplo guía: predecir el precio de una vivienda. Cada vivienda se describe por su superficie, número de recámaras y colonia, y se conoce su precio: 80 m², 2 recámaras, Centro → $1,200,000; 120 m², 3 recámaras

Norte: $2,050,000; 60 m², 1 recámara

Sur: $850,000 (Google for Developers, s. f., define ejemplo, característica, etiqueta, modelo y entrenamiento de forma equivalente).

Dataset: Conjunto organizado de ejemplos con el que se entrena y se prueba un modelo. En el ejemplo, la colección completa de viviendas.

Etiqueta (label): la respuesta correcta que se quiere que el modelo aprenda a predecir; solo existe en el aprendizaje supervisado. En el ejemplo, el precio de la vivienda.

Función de pérdida: fórmula que mide qué tan lejos está la predicción del valor real; el entrenamiento busca minimizarla.

1.2 Clasificación del Aprendizaje Automático

Aplicaciones reales investigadas (10) y su clasificación

Aplicación real	Tipo de ML	Tarea	Algoritmo típico	Descripción breve
1. Filtro de spam del correo electrónico	Supervisado	Clasificación	Naive Bayes, regresión logística	Aprende de correos marcados como spam o no spam y clasifica los nuevos
2. Estimación del precio de viviendas en portales inmobiliarios	Supervisado	Regresión	Regresión lineal, Gradient Boosting	Predice un precio (valor continuo) según superficie y ubicación
3. Detección de retinopatía diabética en imágenes	Supervisado	Clasificación	Redes neuronales convolucionales (CNN)	Se entrena con imágenes revisadas por especialista

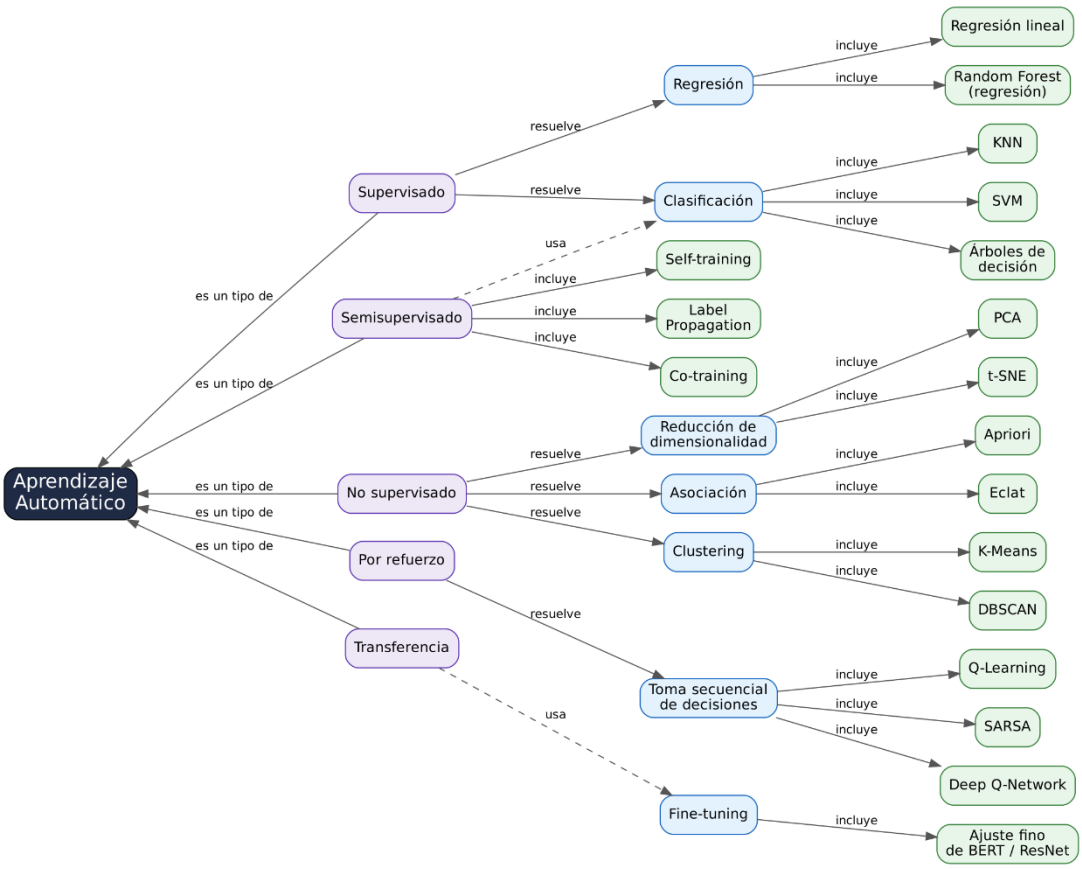
				s y detecta signos de la enfermedad
4. Segmentación de clientes en el comercio	No Supervisado	Clustering	K-Means	Agrupa clientes con hábitos parecidos sin conocer los grupos de antemano
5. Detección de fraude en transacciones con tarjeta	No Supervisado	Detección de anomalías	Isolation Forest	Señala operaciones que se elejan del comportamiento habitual del cliente
6. Recomendaciones “quienes compraron X también compraron Y”	No Supervisado	Asociación	Apiori	Encuentra productos que sueles comprarse juntos en la canasta de compra
7. Visualización y compresión de datos con muchas variables	No Supervisado	Reducción de dimensionalidad	PCA	Resume muchas variables en pocas componentes sin perder lo esencial
8. AlphaGo (juego de Go de DeepMind)	Por refuerzo	Toma secuencial de decisiones	Deep RL (redes de política y valor) + búsqueda Monte Carlo	El agente juega, recibe recompensa al ganar o perder y mejora su estrategia
9. Reconocimiento de voz con pocos datos etiquetados	Semisupervisado	Clasificación	Self-training (pseudoetiquetado)	Pocos ejemplos etiquetados y muchos sin

				etiquetar; el modelo etiqueta los más seguros.
10. Diagnóstico de enfermedades en hojas de cultivo	Transferencia	Fine-tuning	ResNet o BERT preentrenados	Parte de un modelo ya entrenado y lo ajusta con un conjunto pequeño propio.

En el **supervisado** los datos traen la respuesta (etiqueta); en el **no supervisado** no, y el modelo busca estructura; en el **refuerzo un agente** aprende por ensayo y error con recompensas (Microsoft, s. f.; Sutton y Barto, 2018); el **semisupervisado** mezcla pocos datos etiquetados con muchos sin etiquetar y la **transferencia** reutiliza un modelo ya entrenado (IBM, s.f.).

2.1 Grafo de taxonomía del ML

El árbol parte del nodo raíz (Aprendizaje Automático), baja a los cinco tipos, luego a las tareas y por último termina en algoritmos representativos.



Cómo leer las aristas:

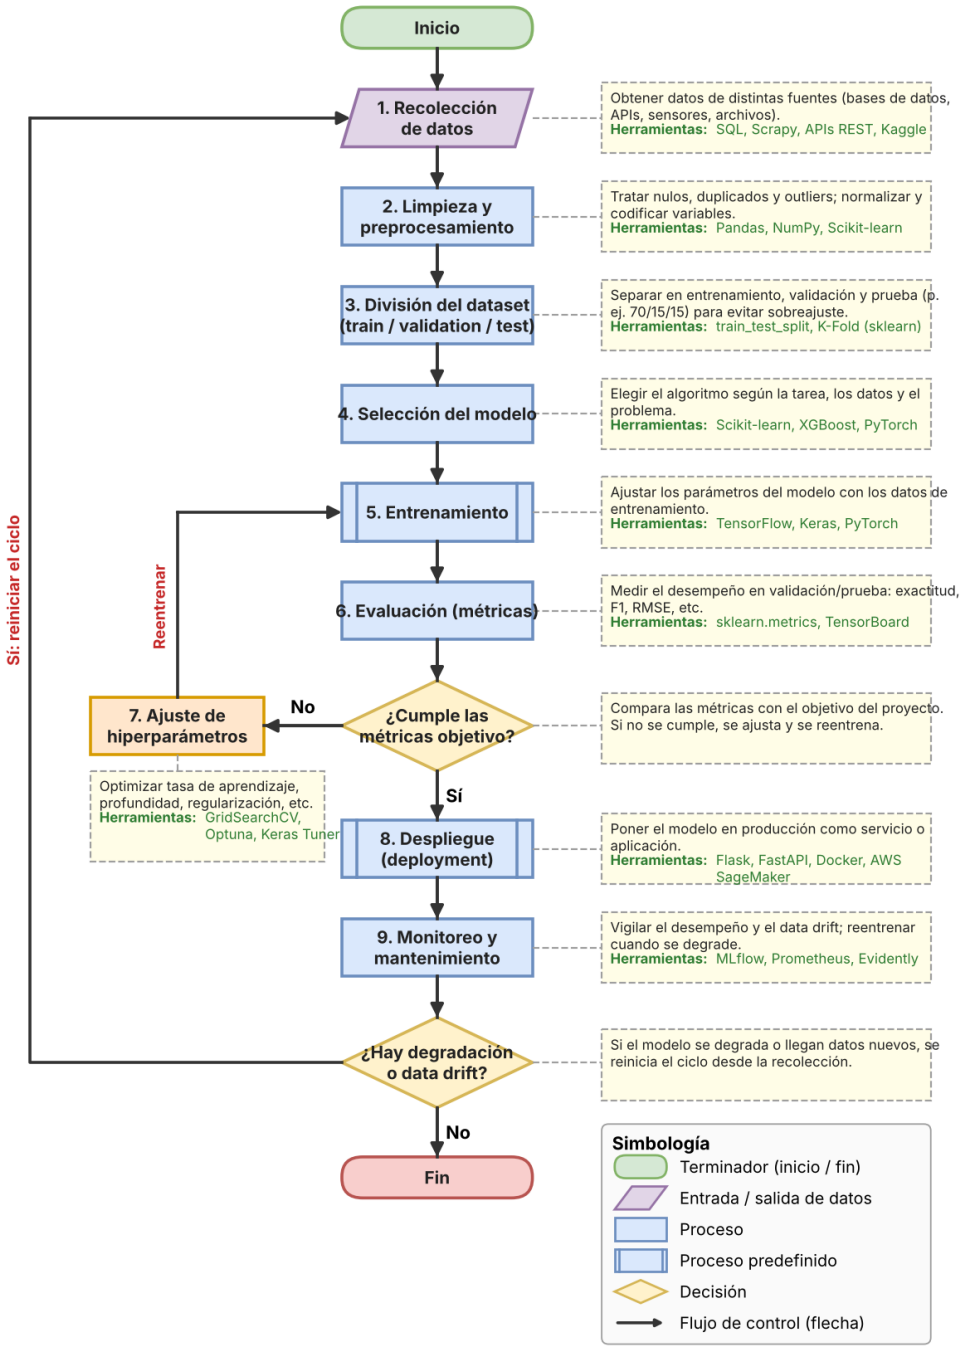
“es un tipo de”: cada tipo de aprendizaje apunta a la raíz (Supervisado es un tipo de Aprendizaje Automático)

“resuelve”: un tipo de aprendizaje resuelve ciertas tareas (No supervisado resuelve Clustering, Reducción de dimensionalidad y Asociación)

“incluye”: una tarea incluye algoritmos concretos (Clasificación incluye KNN y SVM)

“usa”: relación transversal; Semisupervisada usa Clasificación (con pocas etiquetas) y Transferencia usa Fine-tuning de un modelo preentrenado.

2.2 Diagrama de flujo del ciclo de vida de un modelo de ML



2.3 Tabla comparativa de métricas de evaluación

TIPO DE ML	MÉTRICAS TÍPICAS	FÓRMULA / DEFINICIÓN
Supervisado (clasificación)	• Exactitud (accuracy) • Precisión • Exhaustividad (recall) F1 • AUC-ROC	TP, TN, FP y FN son verdaderos/falsos positivos y negativos. Exactitud = (TP + TN) / (TP + TN + FP + FN) Precisión = TP / (TP + FP) Recall = TP / (TP + FN) F1 = 2 · (Precisión · Recall) / (Precisión + Recall) AUC-ROC = área bajo la curva de la tasa de verdaderos positivos contra la de falsos positivos (0.5 ≈ azar; 1 = perfecto).
Supervisado (regresión)	• Error absoluto medio (MAE) • Error cuadrático medio (MSE) • Raíz del MSE (RMSE) • Coeficiente R2	MAE = (1/n) Σ |yi − ŷi | MSE = (1/n) Σ (yi − ŷi) 2 RMSE = √MSE R 2 = 1 − Σ (yi − ŷi) 2 / Σ (yi − ȳ)2 (ȳ = promedio de los valores reales; R2 cercano a 1 indica buen ajuste).
No supervisado	• Inercia (WCSS) • Coeficiente de silueta • Índice de Davies-Bouldin • Varianza explicada (PCA)	Inercia = Σ ‖x − μ c ‖ 2 , sumando sobre todos los puntos x, con μ c el centro del clúster de x (menor = grupos más compactos) Silueta s = (b − a) / max(a, b), con a = distancia media dentro del clúster y b = distancia media al clúster vecino más cercano (de −1 a 1; mayor es mejor) Davies-Bouldin = promedio de la mayor similitud entre cada clúster y otro (menor es mejor) Varianza explicada = λi / Σj λj (proporción de la varianza que retiene cada componente).
Por refuerzo	• Retorno acumulado descontado • Recompensa promedio por episodio • Función de valor Q • Tasa de éxito	Gt = Σk=0 ∞ γk Rt+k+1, con factor de descuento γ ∈ [0, 1] Recompensa promedio = (1/N) Σ G(e) sobre N episodios Q(s, a) = E[Gt | St = s, At = a] (retorno esperado al tomar la acción a en el estado s) Tasa de éxito = episodios exitosos / episodios totales.

Conclusiones

El aprendizaje automático cambia la forma de resolver problemas: en vez de escribir reglas, se le dan datos al sistema para que las descubra. Por eso la calidad y representatividad de los datos pesa tanto como la elección del algoritmo. La clasificación en supervisado, no supervisado, por refuerzo, semisupervisado y transferencia ayuda a elegir el modelo adecuado: si hay etiquetas se usa clasificación o regresión; si no las hay, clustering, asociación o reducción de dimensionalidad; si hay un agente que decide en secuencia, refuerzo; y si faltan datos, transferencia o semisupervisado. El ciclo de vida muestra que construir un modelo no termina al entrenarlo: hay que dividir bien los datos, evaluarlo con métricas adecuadas, ajustarlo, desplegarlo y vigilarlo, porque en el mundo real los datos cambian. Cada tipo de problema se mide con métricas distintas (F1 en clasificación, RMSE en regresión, silueta en clustering, retorno acumulado en refuerzo). Elegir la métrica equivocada puede hacer parecer bueno a un modelo que no lo es. Estos modelos pueden aportar valor social (diagnóstico temprano, detección de fraude, atención de incidencias públicas), siempre que se cuiden el sesgo en los datos, la privacidad y la revisión humana de las decisiones. Esto prepara el terreno para la Sección 3, donde se argumentará por escrito la solución de una problemática social.

Referencias

Anthropic. (2026). Claude Sonnet 5.5 [Modelo de lenguaje de gran tamaño]. https://claude.ai

Google for Developers. (s. f.). Aprendizaje supervisado. Machine Learning. Recuperado el 5 de noviembre de 2026 de https://developers.google.com/machine-learning/intro-to-ml/supervised

IBM. (s. f.). Introduction to machine learning. IBM Developer. Recuperado el 5 de noviembre de 2026 de https://developer.ibm.com/articles/what-is-machine-learning/

Microsoft. (s. f.). Types of machine learning. Microsoft Learn. Recuperado el 5 de noviembre de 2026 de https://learn.microsoft.com/en-us/training/modules/a-guide-to-artificial-intelligence/5-types-of-machine-learning

Mitchell, T. M. (1997). Machine learning. McGraw-Hill.

Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. IBM Journal of Research and Development, 3(3), 210–229. https://doi.org/10.1147/rd.33.0210

scikit-learn developers. (s. f.). 3. Model selection and evaluation. Scikit-learn. Recuperado el 5 de noviembre de 2026 de https://scikit-learn.org/dev/model_selection.htm

Sutton, R. S., y Barto, A. G. (2018). Reinforcement learning: An introduction (2.ª ed.). MIT Press.